

Modelo híbrido de aprendizado de máquina para extração de características em imagens de radiografia de tórax

Rodrigo Marcel Araujo Oliveira

Caroline Ribeiro Figueredo

Luciano Almeida da Silva

Prof. Dr. Paulo César Machado de Abreu Farias

Prof. Dr. Ângelo Márcio Oliveira Sant'Anna

Escola Politécnica,
Universidade Federal da Bahia (UFBA)

July 6, 2023



1 Introdução

2 Estudo de caso

3 Revisão da literatura

4 Metodologia

5 Resultados

6 Conclusão

7 Referências



Indústria 4.0

- A Indústria 4.0 [1] é caracterizada pela integração de diferentes tecnologias como Inteligência Artificial (IA), robótica, computação em nuvem, etc.
- A aprendizagem profunda é um ramo da IA e tem aplicações em diversas áreas, como na área da saúde para detecção de anomalias em imagens médicas, e pode auxiliar profissionais da saúde na tomada de decisões, permitindo um diagnóstico mais rápido e preciso [2].
- A radiografia de tórax é uma ferramenta fundamental para o diagnóstico de doenças, pois permite que os médicos monitorem e avaliem as condições físicas do paciente.



Indústria 4.0

- A Indústria 4.0 [1] é caracterizada pela integração de diferentes tecnologias como Inteligência Artificial (IA), robótica, computação em nuvem, etc.
- A aprendizagem profunda é um ramo da IA e tem aplicações em diversas áreas, como na área da saúde para detecção de anomalias em imagens médicas, e pode auxiliar profissionais da saúde na tomada de decisões, permitindo um diagnóstico mais rápido e preciso [2].
- A radiografia de tórax é uma ferramenta fundamental para o diagnostico de doenças, pois permite que os médicos monitorem e avaliem as condições físicas do paciente.



Indústria 4.0

- A Indústria 4.0 [1] é caracterizada pela integração de diferentes tecnologias como Inteligência Artificial (IA), robótica, computação em nuvem, etc.
- A aprendizagem profunda é um ramo da IA e tem aplicações em diversas áreas, como na área da saúde para detecção de anomalias em imagens médicas, e pode auxiliar profissionais da saúde na tomada de decisões, permitindo um diagnóstico mais rápido e preciso [2].
- A radiografia de tórax é uma ferramenta fundamental para o diagnóstico de doenças, pois permite que os médicos monitorem e avaliem as condições físicas do paciente.



1 Introdução

2 Estudo de caso

3 Revisão da literatura

4 Metodologia

5 Resultados

6 Conclusão

7 Referências



Conjunto de dados

- O conjunto de dados utilizado está disponível em [3], e este possui 5863 imagens de Raios X com três categorias, normal, pneumonia bacteriana e pneumonia viral.
- Para desenvolvimento desse estudo, foi feita a separação do conjunto em duas categorias, normal e pneumonia.
- O conjunto de amostras de 5216 imagens foi separado para treinamento do modelo, com 74,3% classificadas com pneumonia e 25,7% normal. O conjunto de teste contém 624 imagens com 62,5% e 37,5%, respectivamente, pneumonia e tórax normal. O conjunto de validação contém com 16 imagens, com 8 de cada categoria.



Conjunto de dados

- O conjunto de dados utilizado está disponível em [3], e este possui 5863 imagens de Raios X com três categorias, normal, pneumonia bacteriana e pneumonia viral.
- Para desenvolvimento desse estudo, foi feita a separação do conjunto em duas categorias, normal e pneumonia.
- O conjunto de amostras de 5216 imagens foi separado para treinamento do modelo, com 74,3% classificadas com pneumonia e 25,7% normal. O conjunto de teste contém 624 imagens com 62,5% e 37,5%, respectivamente, pneumonia e tórax normal. O conjunto de validação contém com 16 imagens, com 8 de cada categoria.




Conjunto de dados

- O conjunto de dados utilizado está disponível em [3], e este possui 5863 imagens de Raios X com três categorias, normal, pneumonia bacteriana e pneumonia viral.
- Para desenvolvimento desse estudo, foi feita a separação do conjunto em duas categorias, normal e pneumonia.
- O conjunto de amostras de 5216 imagens foi separado para treinamento do modelo, com 74,3% classificadas com pneumonia e 25,7% normal. O conjunto de teste contém 624 imagens com 62,5% e 37,5%, respectivamente, pneumonia e tórax normal. O conjunto de validação contém com 16 imagens, com 8 de cada categoria.



Imagens

Exemplos



(a) Normal

(b) Pneumonia

Figure 1: Imagem 10(a) corresponde a uma radiografia de tórax normal e mostra pulmões claros, a image 10(b) exibe um pulmão com pneumonia. As imagens de radiografia de tórax foram selecionadas de cortes retrospectivos de pacientes pediátricos do *Guangzhou Women and Children's Medical Center*.



Objetivos

- Desenvolver uma metodologia baseada em algoritmos de aprendizado de máquina para classificar imagens de indivíduos saudáveis e com pneumonia.
- Adotar uma metodologia com tempo de processamento baixo comparado aos métodos vistos na literatura.



Objetivos

- Desenvolver uma metodologia baseada em algoritmos de aprendizado de máquina para classificar imagens de indivíduos saudáveis e com pneumonia.
- Adotar uma metodologia com tempo de processamento baixo comparado aos métodos vistos na literatura.



- 1 Introdução
- 2 Estudo de caso
- 3 Revisão da literatura
- 4 Metodologia
- 5 Resultados
- 6 Conclusão
- 7 Referências



Aprendizado de máquina para classificação de imagens de radiografia de tórax

- Atualmente pesquisas apontam que a transfêrencia de aprendizado de redes neurais pré-treinadas são alternativas eficientes para modelagem preditiva de alto desempenho [4], e entre as redes neurais amplamente utilizadas estão: ResNet-50, VGG-19, DenseNet201, Inception-V3, MobileNet, Xception, etc.
- O modelo Random Forest foi utilizado para classificar imagens com base em características extraídas da CNN ResNet-50 [5]. Esse estudo utilizou dados de imagens de retinopatia diabética e os autores relatam que a proposta adotada superam arquiteturas como: ResNet-50, VGG-19, Inception-v3, MobileNet, Xception e VGG-16.
- Os trabalhos [6], [7], [8], [9] apresentam diversas arquiteturas de redes neurais pré-treinadas para classificação de radiografia de tórax de indivíduos com COVID-19.



Aprendizado de máquina para classificação de imagens de radiografia de tórax

- Atualmente pesquisas apontam que a transfêrencia de aprendizado de redes neurais pré-treinadas são alternativas eficientes para modelagem preditiva de alto desempenho [4], e entre as redes neurais amplamente utilizadas estão: ResNet-50, VGG-19, DenseNet201, Inception-V3, MobileNet, Xception, etc.
- O modelo Random Forest foi utilizado para classificar imagens com base em características extraídas da CNN ResNet-50 [5]. Esse estudo utilizou dados de imagens de retinopatia diabética e os autores relatam que a proposta adotada superam arquiteturas como: ResNet-50, VGG-19, Inception-v3, MobileNet, Xception e VGG-16.
- Os trabalhos [6], [7], [8], [9] apresentam diversas arquiteturas de redes neurais pré-treinadas para classificação de radiografia de tórax de indivíduos com COVID-19.



Aprendizado de máquina para classificação de imagens de radiografia de tórax

- Atualmente pesquisas apontam que a transfêrencia de aprendizado de redes neurais pré-treinadas são alternativas eficientes para modelagem preditiva de alto desempenho [4], e entre as redes neurais amplamente utilizadas estão: ResNet-50, VGG-19, DenseNet201, Inception-V3, MobileNet, Xception, etc.
- O modelo Random Forest foi utilizado para classificar imagens com base em características extraídas da CNN ResNet-50 [5]. Esse estudo utilizou dados de imagens de retinopatia diabética e os autores relatam que a proposta adotada superam arquiteturas como: ResNet-50, VGG-19, Inception-v3, MobileNet, Xception e VGG-16.
- Os trabalhos [6], [7], [8], [9] apresentam diversas arquiteturas de redes neurais pré-treinadas para classificação de radiografia de tórax de indivíduos com COVID-19.



- 1 Introdução
- 2 Estudo de caso
- 3 Revisão da literatura
- 4 Metodologia**
- 5 Resultados
- 6 Conclusão
- 7 Referências



Fluxograma do projeto

Fluxograma

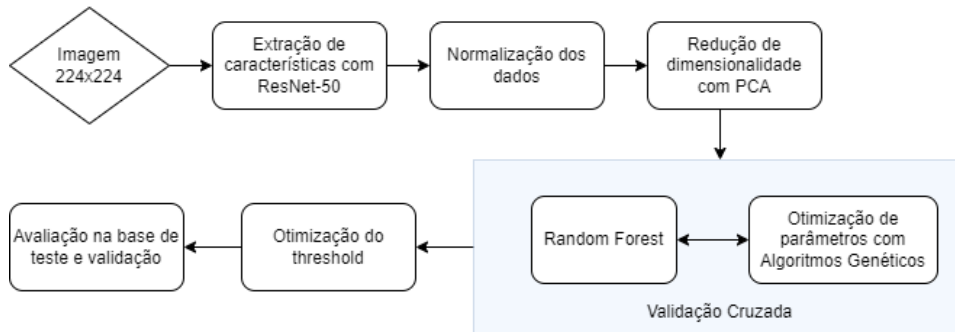


Figure 2: Etapas do desenvolvimento do projeto.



Extração de características

Resnest-50

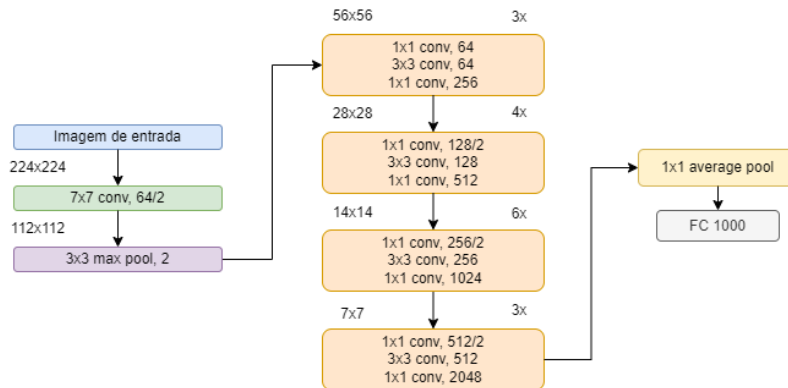



Figure 3: Arquitetura da Resnest-50.




Análise de Componentes Principais (PCA)

PCA



(a) Dimensão original



(b) Redução de dimensionalidade

Figure 4: Imagem 4(a) representa os dados na dimensão original, a imagem 4(b) contém informações consolidadas nas duas componentes principais.



Algoritmos Genético (AG)

Otimização de parâmetros com AG

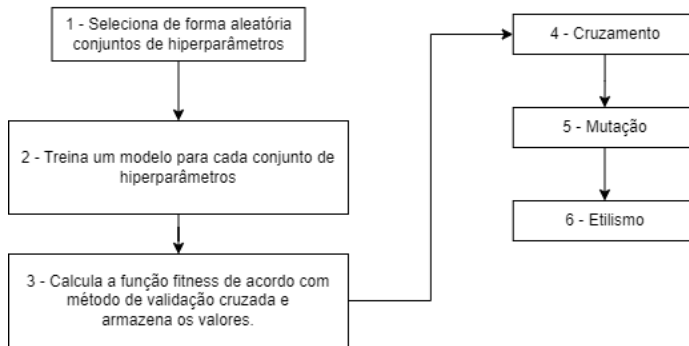


Figure 5: Etapas do processo GAsearchCV.



Random Forest (RF)

Diagrama do RF

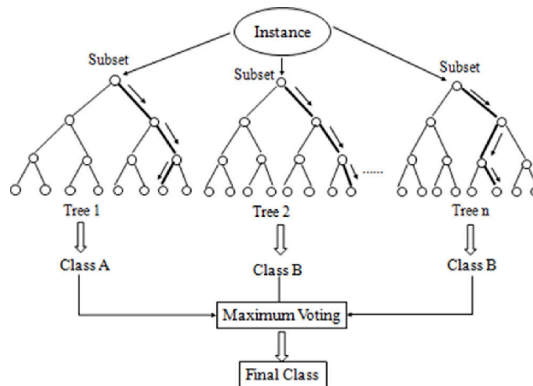


Figure 6: Diagrama do RF no contexto de classificação [10].



Avaliação dos resultados

Métricas baseadas na matriz de confusão

- Número de verdadeiros positivos (TP); falsos positivos (FP); falsos negativos (FN); verdadeiros negativos (TN).
- Curva de característica de operação do receptor (ROC)
- Accuracy
- Precision
- Recall
- Specificity
- F_1 score

Validação cruzada

- k-fold



- 1 Introdução
- 2 Estudo de caso
- 3 Revisão da literatura
- 4 Metodologia
- 5 Resultados**
- 6 Conclusão
- 7 Referências



Validação cruzada com GASearchCV

Função fitness

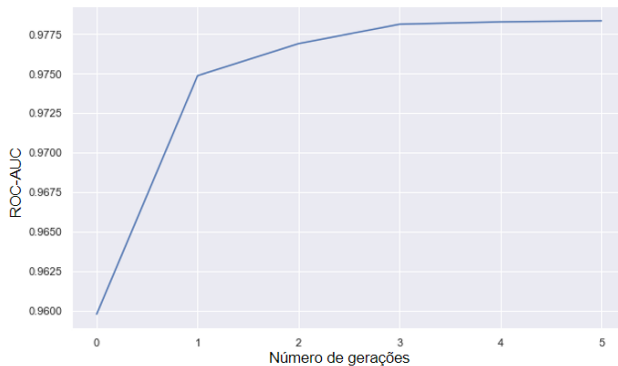


Figure 7: ROC-AUC em função do número de gerações.



Curvas de aprendizado do RF

Desempenho do classificador RF




Figure 8: ROC-AUC no processo de validação cruzada.



Avaliação do classificador RF no conjunto de Treino

Distribuição de probabilidade




Figure 9: Distribuição da probabilidade do modelo RF.



Matriz de confusão

Conjuntos de dados




Figure 10: Matriz de confusão para cada conjunto de dados



Desempenho nos conjuntos de treino, teste e validação

Table 1: Métricas de desempenho

Métricas de avaliação	Conjuntos de dados		
	Treino	Teste	Validação
<i>Accuracy</i>	93%	83%	88%
<i>Precision</i>	98%	82%	80%
<i>Recall</i>	92%	92%	100%
<i>Specificity</i>	95%	67%	75%
<i>F₁-score</i>	95%	87%	89%
<i>ROC-AUC</i>	93%	79%	88%



- 1 Introdução
- 2 Estudo de caso
- 3 Revisão da literatura
- 4 Metodologia
- 5 Resultados
- 6 Conclusão
- 7 Referências



Conclusões

- O modelo híbrido usando Resnet-50 e Random Forest foi capaz de aprender estruturas não lineares para classificação de imagens de radiografia de tórax de indivíduos saudáveis e com pneumonia.
- O treinamento do modelo foi realizado com uma máquina comum, o que torna o experimento alcançado seja facilmente reproduzível. Essa foi a razão para não usar uma CNN para classificação.
- Os resultados desse trabalho contribuem para desenvolvimento de sistemas de IA com alto desempenho. O processamento dessas informações pode contribuir para agilizar o diagnóstico de doenças tratáveis como a pneumonia, facilitando o tratamento precoce.



Conclusões

- O modelo híbrido usando Resnet-50 e Random Forest foi capaz de aprender estruturas não lineares para classificação de imagens de radiografia de tórax de indivíduos saudáveis e com pneumonia.
- O treinamento do modelo foi realizado com uma máquina comum, o que torna o experimento alcançado seja facilmente reproduzível. Essa foi a razão para não usar uma CNN para classificação.
- Os resultados desse trabalho contribuem para desenvolvimento de sistemas de IA com alto desempenho. O processamento dessas informações pode contribuir para agilizar o diagnóstico de doenças tratáveis como a pneumonia, facilitando o tratamento precoce.



Conclusões

- O modelo híbrido usando Resnet-50 e Random Forest foi capaz de aprender estruturas não lineares para classificação de imagens de radiografia de tórax de indivíduos saudáveis e com pneumonia.
- O treinamento do modelo foi realizado com uma máquina comum, o que torna o experimento alcançado seja facilmente reproduzível. Essa foi a razão para não usar uma CNN para classificação.
- Os resultados desse trabalho contribuem para desenvolvimento de sistemas de IA com alto desempenho. O processamento dessas informações pode contribuir para agilizar o diagnóstico de doenças tratáveis como a pneumonia, facilitando o tratamento precoce.



- 1 Introdução
- 2 Estudo de caso
- 3 Revisão da literatura
- 4 Metodologia
- 5 Resultados
- 6 Conclusão
- 7 Referências



- [1] S. M. Acosta, R. M. A. Oliveira, and J. M. O. Sant'Anna, "Machine learning algorithms applied to intelligent tyre manufacturing," *International Journal of Computer Integrated Manufacturing*, pp. 1–11, 2 2023.
- [2] G. Silva, L. Duarte, M. Shirassu, S. Peres, M. de Moraes, and A. Chiavegatto Filho, "Machine learning for longitudinal mortality risk prediction in patients with malignant neoplasm in São Paulo, Brazil," *Artificial Intelligence in the Life Sciences*, vol. 3, p. 100061, 12 2023.
- [3] D. Kermany, K. Zhang, and M. Goldbaum, "Labeled Optical Coherence Tomography (OCT) and Chest X-Ray Images for Classification," vol. 2, 2018.
- [4] A. Abdollahi, B. Pradhan, N. Shukla, S. Chakraborty, and A. Alamri, "Deep learning approaches applied to remote sensing datasets for road extraction: A state-of-the-art review," *Remote Sensing*, vol. 12, 5 2020.



- [5] M. K. Yaqoob, S. F. Ali, M. Bilal, M. S. Hanif, and U. M. Al-Saggaf, “ResNet Based Deep Features and Random Forest Classifier for Diabetic Retinopathy Detection,” *Sensors (Basel, Switzerland)*, vol. 21, pp. 1–6, 6 2021.
- [6] A. Narin, C. Kaya, and Z. Pamuk, “Automatic Detection of Coronavirus Disease (COVID-19) Using X-ray Images and Deep Convolutional Neural Networks,” *Pattern Analysis and Applications*, vol. 24, pp. 1207–1220, 3 2020.
- [7] A. I. Khan, J. L. Shah, and M. M. Bhat, “CoroNet: A deep neural network for detection and diagnosis of COVID-19 from chest x-ray images,” *Computer methods and programs in biomedicine*, vol. 196, 11 2020.
- [8] M. E. H. Chowdhury, T. Rahman, A. Khandakar, R. Mazhar, M. A. Kadir, Z. B. Mahbub, K. R. Islam, M. S. Khan, A. Iqbal, N. Al-Emadi, M. B. I. Reaz, and T. I. Islam, “Can AI help in screening Viral and COVID-19 pneumonia?,” *IEEE Access*, vol. 8, pp. 132665–132676, 3 2020.



- [9] R. d. S. Farias, K. R. d. S. Oliveira, C. D. M. Regis, C. d. M. Costa, and J. M. Seixas, “Redes Neurais Convolucionais para Classificação da COVID-19 em Imagens de Raio-x de Tórax,” *Anais do 15. Congresso Brasileiro de Inteligência Computacional*, pp. 1–8, 1 2021.
- [10] S. S. Nain, D. Garg, and S. Kumar, “Performance evaluation of the WEDM process of aeronautics super alloy,” *Materials and Manufacturing Processes*, vol. 33, pp. 1793–1808, 12 2018.



Obrigado

Rodrigo Marcel Araujo Oliveira - rodrigomarcel@ufba.br

Caroline Ribeiro Figueredo - carolinefigueredo@ufba.br

Luciano Almeida da Silva - lucianoas@ufba.br

Prof. Dr. Paulo César Machado de Abreu Farias - paulo.farias@ufba.br

Prof. Dr. Ângelo Márcio Oliveira Sant'Anna - angelo.santanna@ufba.br

